HighLoad
для начинающих

highload++ 2014

Конференция разработчиков
высоконагруженных систем

HighLoad для начинающих

Dmitry E. Oboukhov

31 октября 2014

HighLoad, что это?

- Конференция?

HighLoad, что это?

- Конференция?
- Высокая нагрузка?

HighLoad, что это?

- Конференция?
- Высокая нагрузка?
- Миф?!

Высокая нагрузка что это?

Высокая нагрузка что это?

- $53.328 * 10^9$ запросов в секунду?

Высокая нагрузка что это?

- $53.328 * 10^9$ запросов в секунду? - средний CPU

Высокая нагрузка что это?

- $53.328 * 10^9$ запросов в секунду? - средний CPU
- Более реалистично!

Высокая нагрузка что это?

- $53.328 * 10^9$ запросов в секунду? - средний CPU
- Более реалистично!
- 1 запрос в секунду?

Высокая нагрузка что это?

- $53.328 * 10^9$ запросов в секунду? - средний CPU
- Более реалистично!
- 1 запрос в секунду? - любой веб сервер справится?...

Высокая нагрузка что это?

- $53.328 * 10^9$ запросов в секунду? - средний CPU
- Более реалистично!
- 1 запрос в секунду? - любой веб сервер справится?...
  перекодирующий видеоролики? :)

Высокая нагрузка это:

Высокая нагрузка это:

Нагрузка, с которой не справляется железо

Когда это бывает?

Достигнуты технические ограничения

- Сеть
- Память
- CPU
- Хранилище

Дополнительно

- Недоиспользование железа
- Трудности масштабирования

Архитектурные проблемы

Недоиспользование железа

Рассмотрим типичный вебсервер на Perl, Python, Ruby...

Недоиспользование железа

Рассмотрим типичный вебсервер на Perl, Python, Ruby...

Задачи одного цикла

- Чтение запроса из сети.
- Парсинг запроса http.
- Валидация запроса, выбор контроллера.
- Запрос(ы) к хранилищу данных.
- Формирование ответа (template).
- Отправка ответа клиенту.

Недоиспользование железа

Рассмотрим типичный вебсервер на Perl, Python, Ruby...

Задачи одного цикла

- Чтение запроса из сети.
- Парсинг запроса http.
- Валидация запроса, выбор контроллера.
- Запрос(ы) к хранилищу данных.
- Формирование ответа (template).
- Отправка ответа клиенту.

Традиционная реализация (apache)

- один процесс на один цикл
- один тред на один цикл

Недоиспользование железа

Начались разговоры о HighLoad?

- Увеличение числа процессов/тредов.
- Увеличение числа серверов.

Недоиспользование железа

Вернемся к рассматриваемому серверу

- Проблемы наступили при ≈100 запросах в секунду.
- Увеличили число процессов в работе.
  - Помогло.
- Новые проблемы при ≈150 запросов в секунду.
- Дальнейшее увеличение числа процессов помогает слабо.

Недоиспользование железа

Что делать?

Недоиспользование железа

Что делать?

- Переписывать?

Недоиспользование железа

Что делать?

- Переписывать?
  - Мы над этим 3 года работали!

Недоиспользование железа

Что делать?

- Переписывать?
  - Мы над этим 3 года работали!
- Добавлять второй сервер?

Недоиспользование железа

Что делать?

- Переписывать?
  - Мы над этим 3 года работали!
- Добавлять второй сервер?
  - Это тоже не просто!
  (бизнеслогика)

Спокойно!

- Провести измерения.
- Провести анализ архитектуры.
- Найти слабые места.

Недоиспользование железа

Измерения

Чтение запроса из сети.	15K RPS
Парсинг запроса, контроллер.	150K RPS/CPU
Запросы к хранилищу.	60K RPS
Формирование ответа	100K RPS/CPU
Отправка ответа клиенту.	15K RPS

Недоиспользование железа

Итого

$$\frac{1}{\frac{1}{15 \cdot 10^3} + \frac{1}{150 \cdot 10^3} + \frac{1}{60 \cdot 10^3} + \frac{1}{100 \cdot 10^3} + \frac{1}{15 \cdot 10^3}} = 6000 RPS$$

Недоиспользование железа

Итого

$$\frac{1}{\frac{1}{15 \cdot 10^3} + \frac{1}{150 \cdot 10^3} + \frac{1}{60 \cdot 10^3} + \frac{1}{100 \cdot 10^3} + \frac{1}{15 \cdot 10^3}} = 6000 RPS$$

Но, позвольте!

- У нас проблемы на 150 RPS!
- Тут что-то не так!

Недоиспользование железа

Начинаем разбираться

- Хранилище выходит на свои RPS при достаточно большом числе соединений к нему.
- Либо хранилище надо располагать локально.

  неприемлемо.
- То же самое и с взаимодействием с клиентом.

Недоиспользование железа

Резюме ситуации, еще раз

- Имеется 100500 строк кода, над которым работали несколько лет.
- Этот код AS IS по результатам измерений может выдавать гораздо больше RPS чем в реальности.
- Проблемы начинаются на уровне RPS на порядок меньших, нежели расчетные.

Недоиспользование железа

Работа сервера

- Запросу выделяется CPU.
- Ожидаются данные запроса.
- Диспетчеризация.
- Запросы в БД.
- Ожидаются ответы из БД.
- Формируется ответ.
- Ответ отправляется клиенту.

Недоиспользование железа

Работа сервера

- Запросу выделяется CPU.
- Ожидаются данные запроса.
- Диспетчеризация.
- Запросы в БД.
- Ожидаются ответы из БД.
- Формируется ответ.
- Ответ отправляется клиенту.

Магазин обуви

- Клиенту выделяется менеджер.
- Сопровождает клиента.
- Может сходить на склад за нужным размером.
- Ожидает товара со склада/решения клиента.
- Пробивает чек на кассе.
- Прощается с клиентом.

Недоиспользование железа

Измеряем

Ожидание запроса (данных) от пользователя.	70 мкс
Парсинг запроса, валидация.	6 мкс
Формирование запроса (запросов) в БД.	1 мкс
Ожидание ответа (ответов) из БД.	16 мкс
Соединение данных из БД с шаблоном.	10 мкс
Ожидание отправки данных клиенту.	70 мкс

Недоиспользование железа

Итого

- Код выполнялся: $6 + 1 + 10 = 17$ мкс
- Чего-либо ожидали: $70 + 16 + 70 = 156$ мкс

Недоиспользование железа

Итого

- Код выполнялся: $6 + 1 + 10 = 17$ мкс
- Чего-либо ожидали: $70 + 16 + 70 = 156$ мкс
- Код выполняется только 10% времени!
- И при этом тормозит!

Недоиспользование железа

```
#include <unistd.h>

int main(int argc, char **argv) {
        int i;
        for (;;) {
                usleep(70);     usleep(7);
                usleep(17);     usleep(10);
                usleep(70);
        }
}
```

Недоиспользование железа

Итого

- Код, делающий только sleep в цикле неплохо грузит CPU
  - по моим измерениям - где-то 15% загрузки на CPU
- Запустив десяток таких “воркеров”, получаем примерно такую же нагрузку как на проблемном сервере.
- Понятно что пример синтетический (есть вопросы к реализации usleep).

Недоиспользование железа

Итого

- Код, делающий только sleep в цикле неплохо грузит CPU
  - по моим измерениям - где-то 15% загрузки на CPU
- Запустив десяток таких “воркеров”, получаем примерно такую же нагрузку как на проблемном сервере.
- Понятно что пример синтетический (есть вопросы к реализации usleep).

Вернемся к нашему серверу

- Каждая отдельная часть имеет хорошую производительность достаточную для развития проекта еще на несколько лет вперед.
- Большую часть времени (90%) наш код проводит в ожидании.
- Что делать?

Просто реорганизовать код

Просто реорганизовать код

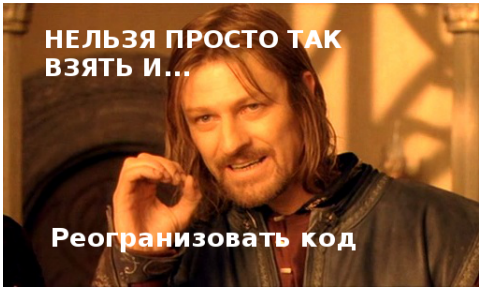

Событийно-ориентированное программирование

Компьютер — это конечный автомат. Треды для тех людей, которые не умеют программировать конечные автоматы.

Алан Кокс

Избавимся от тредов!

- и процессов.

От магазина обуви к продуктовому!

Особенности продуктового магазина

- Клиенты собираются в очереди.
- Продавец обслуживает клиентов по очереди и без простоя.
- Простой продавца возможен только при отсутствии клиентов.
- Один продавец может обслужить в десятки раз больше клиентов.
- PROFIT?

Событийно-ориентированное программирование

Машина событий

- Исполнитель заявляет о готовности выполнить задачу.
  - подписывается на событие: “Свободная касса!”
- При появлении задачи исполнитель начинает ее выполнение немедленно.
- Если задача требует ожидания - ставит ожидающего в очередь и переходит к выполнению другой задачи.

Событийно-ориентированное программирование

Машина событий

- Исполнитель заявляет о готовности выполнить задачу.
  - подписывается на событие: “Свободная касса!”
- При появлении задачи исполнитель начинает ее выполнение немедленно.
- Если задача требует ожидания - ставит ожидающего в очередь и переходит к выполнению другой задачи.

Типичная реализация

- Подписка на задачу - регистрация callback.
- Выполнение задачи - вызов callback.
- Ожидание - return из callback.

Событийно-ориентированное программирование

Перестроим наш сервер

- Ожидание запроса от пользователя.
  - заменится регистрацией callback "пришел запрос от пользователя"
- Диспетчеризация запроса - не изменится
- Формирование запросов в БД - не изменится
- Ожидание ответа из БД.
  - заменится регистрацией callback "пришел ответ из БД"
- Формирование ответа - не изменится
- Ожидание отправки данных клиенту.
  - заменится регистрацией callback "данные пользователю отправлены"

Событийно-ориентированное программирование

Переписываем одну страничку и изменяем

- Производительность одного сервера выросла в >10 раз
- Одного CPU/коннекта к БД достаточно для еще нескольких лет роста нагрузки.
- Но слишком много переделок!

Событийно-ориентированное программирование

Переписываем одну страничку и изменяем

- Производительность одного сервера выросла в >10 раз
- Одного CPU/коннекта к БД достаточно для еще нескольких лет роста нагрузки.
- Но слишком много переделок!

Проблемы

- Сохранение контекста между callback
- Ветвления
- Обработка исключительных ситуаций

Событийно-ориентированное программирование

Что затронуто изменениями

- Интерфейс с вебсервером - некритично.
- Интерфейс с БД.
  - критично. Много кода бизнеслогики поехало в callbacks. Сложную логику практически невозможно реализовать. Требуется переписывание 90% проекта.
- Интерфейс с сетью (если он есть)
  - так же переехал в callbacks.

Событийно-ориентированное программирование

Плюсы Обувного магазина

- Контекст задачи можно хранить на текущем стеке (свалить на менеджера).
- Процесс можно прервать в любой момент.
- Произвольное ветвление (можно ходить по разным отделам в произвольном порядке).

Плюсы продуктового магазина

- Менеджеры не простаивают

Событийно-ориентированное программирование

Соединим плюсы обоих подходов

Пишем свой планировщик (fibers).

- Невытесняющая многозадачность
- Простое порождение “процессов”
- Простое API
  Три основных метода
  - Создать процесс (create, async)
  - Передать управление планировщику (yield, cede)
  - Разбудить выбранный процесс (wakeup, ready)

Событийно-ориентированное программирование

Интеграция планировщика с машиной событий

Структура кода теперь выглядит так:

- Подписка на событие (регистрация callback).
- Передача управления планировщику (yield, cede).
- Событие будит (wakeup) текущий процесс.
- Процесс обрабатывает события используя данные переданные в callback.

Событийно-ориентированное программирование

Интеграция планировщика с машиной событий

Структура кода теперь выглядит так:

- Подписка на событие (регистрация callback).
- Передача управления планировщику (yield, cede).
- Событие будит (wakeup) текущий процесс.
- Процесс обрабатывает события используя данные переданные в callback.

Итого

Вернулись к (почти) традиционному виду программы.

Событийно-ориентированное программирование

Вернемся к нашему серверу

- Добавляем машину событий
- Добавляем библиотеку fibers
- Переписываем интерфейс с вебсервером (врапперы).
- Переписываем интерфейс с БД (врапперы).
- Переписываем другие сетевые обращения (если есть).

Событийно-ориентированное программирование

Вернемся к нашему серверу

- Добавляем машину событий
- Добавляем библиотеку fibers
- Переписываем интерфейс с вебсервером (врапперы).
- Переписываем интерфейс с БД (врапперы).
- Переписываем другие сетевые обращения (если есть).
- Итого: переписываем около 5% кода.
- PROFIT!

Библиотеки и языки

Библиотеки и языки

- Perl

Библиотеки и языки

- Perl
  Coro + AnyEvent

Библиотеки и языки

- Perl
  Coro + AnyEvent
- Python

Библиотеки и языки

- Perl
  Coro + AnyEvent
- Python
  fibers + twisted

Библиотеки и языки

- Perl
  Coro + AnyEvent
- Python
  fibers + twisted
- PHP5

Библиотеки и языки

- Perl
  Coro + AnyEvent
- Python
  fibers + twisted
- PHP5
  появился оператор yield, fiber

Что дальше?

- Используем fiber'ы/event-машины в том языке к которому привыкли
- Рассматриваем существующие варианты
  - Node.JS
    - отказались от парадигмы fibers
    но в последнее время появились подвижки.

Что дальше?

- Используем fiber'ы/event-машины в том языке к которому привыкли
- Рассматриваем существующие варианты
  - Node.JS
    - отказались от парадигмы fibers
    но в последнее время появились подвижки.
  - Tarantool...

Tarantool

- Полноценный app-сервер
- fibers, libev
- БД на борту
  - in-memory
  - disk
- Сокеты, диск, http-сервер, очереди

Недостатки

- Для больших проектов одного CPU все-таки маловато
- Реализации fiber'ов для традиционных ЯП плохо масштабируются по CPU/хостам.

Перспектива

- Erlang
  - хорошее масштабирование по CPU и хостам
  - очень качественное решение
  - высокий порог вхождения
- Go
  - более низкий порог вхождения

Дзен

HighLoad и базы данных

Что делать?

- Переезжать на другое железо?
- Переходить на другую БД?

HighLoad и базы данных

Что делать?

- Переезжать на другое железо?
- Переходить на другую БД?
- Опять смотреть на архитектуру!

Вопрос

Что представляет из себя любая БД?

Философия: что такое БД?

Философия: что такое БД?

- Массив записей.

Философия: что такое БД?

- Несколько массивов записей.

Философия: что такое БД?

- Несколько массивов записей.
- Средства ускорения поиска по массиву (индексы).

Философия: что такое БД?

- Несколько массивов записей.
- Средства ускорения поиска по массиву (индексы).
- И...

Философия: что такое БД?

- Несколько массивов записей.
- Средства ускорения поиска по массиву (индексы).
- И...ВСЕ!

Виды поисков по массиву

- Сканирование: $O(N)$
- Индексированный: $O(\ln N)$ (иногда $O(1)$).

Выбор из двух массивов: JOIN

```
SELECT
    *
FROM
    "users"
JOIN
    "roles" ON "users"."id" = "roles"."uid"
WHERE
        "roles"."id" IN (10, 20, 30)
    AND "users"."id" IN (30, 40, 50)
```

Выбор из двух массивов: JOIN

- Выбираются записи первого массива $K1 \cdot O(\ln N1)$
  $K1$ определяется на стадии выборки из первого индекса
- Сопоставляются записям второго: $K2 \cdot O(\ln N2)$
  На этом шаге становится известным $K2$
- Результат фильтруется: $O(K2)$ по условиям, если таковые еще не отфильтрованы.

Итого

$$K1 \cdot O(\ln N1) + K2 \cdot O(\ln N2) + O(K2)$$

Пути оптимизации?

- Попытаться предсказать что меньше $K1$ или $K2$
- Последовательные элементы из индекса иногда можно выбрать за время $\ln N + K1 \cdot c$
- Фильтрация на стадии JOIN
- И... все?!

Пути оптимизации?

- Попытаться предсказать что меньше $K1$ или $K2$
- Последовательные элементы из индекса иногда можно выбрать за время $\ln N + K1 \cdot c$
- Фильтрация на стадии JOIN
- И... все?!
- Денормализация.

Усложняем задачу

- Увеличиваем число таблиц в JOIN
- Вводим дополнительные условия WHERE
- Даже оценить ресурсы на выполнение запросов становится сложно.

Почему популярны NoSQL?

Почему популярны NoSQL?

Почему популярны NoSQL?

Почему популярны NoSQL?

- Они более быстрые?

Почему популярны NoSQL?

- Они более быстрые?
  см. соседние доклады: PostgreSQL быстрее MongoDB в 10 раз.

Почему популярны NoSQL?

- Они более быстрые?
  см. соседние доклады: PostgreSQL быстрее MongoDB в 10 раз.
- Позволяют хранить слабоструктурированные данные?

Почему популярны NoSQL?

- Они более быстрые?
  см. соседние доклады: PostgreSQL быстрее MongoDB в 10 раз.
- Позволяют хранить слабоструктурированные данные?
  hstore, arrays, composite появились в PostgreSQL много лет назад.

Почему популярны NoSQL?

- Они более быстрые?
  см. соседние доклады: PostgreSQL быстрее MongoDB в 10 раз.
- Позволяют хранить слабоструктурированные данные?
  hstore, arrays, composite появились в PostgreSQL много лет назад.
- Шардинг/репликация?

Почему популярны NoSQL?

- Они более быстрые?
  см. соседние доклады: PostgreSQL быстрее MongoDB в 10 раз.
- Позволяют хранить слабоструктурированные данные?
  hstore, arrays, composite появились в PostgreSQL много лет назад.
- Шардинг/репликация?
  решения для PostgreSQL существуют в избытке.

Почему популярны NoSQL?

- Они более быстрые?
  см. соседние доклады: PostgreSQL быстрее MongoDB в 10 раз.
- Позволяют хранить слабоструктурированные данные?
  hstore, arrays, composite появились в PostgreSQL много лет назад.
- Шардинг/репликация?
  решения для PostgreSQL существуют в избытке.
- Может быть NoSQL имеют лучшие возможности по предсказанию плана выполнения запроса?

Почему популярны NoSQL?

- Они более быстрые?
  см. соседние доклады: PostgreSQL быстрее MongoDB в 10 раз.
- Позволяют хранить слабоструктурированные данные?
  hstore, arrays, composite появились в PostgreSQL много лет назад.
- Шардинг/репликация?
  решения для PostgreSQL существуют в избытке.
- Может быть NoSQL имеют лучшие возможности по предсказанию плана выполнения запроса?
  большинство NoSQL не умеет JOIN.
- Что еще?

Философия: что такое БД?

- Массив(ы) записей.
- Индексы.

Почему популярны noSQL?

Почему популярны noSQL?

- Они не умеют JOIN.

Почему популярны noSQL?

- Они не умеют JOIN.
- Это заставляет программиста помнить о том что такое БД.

Почему популярны noSQL?

- Они не умеют JOIN.
- Это заставляет программиста помнить о том что такое БД.
- Положительно влияет на архитектуру приложения.

О БД Tarantool

О БД Tarantool

- Это не БД.

О БД Tarantool

- Это не БД.
- Это APP-сервер с БД на борту.

О БД Tarantool

- Это не БД.
- Это APP-сервер с БД на борту.
- JOIN не нужны: денормализация.

highload++ 2014

Конференция разработчиков
высоконагруженных систем